

UNICAMP

UTILIZAÇÃO DE SÉRIES TEMPORAIS PARA PREDIÇÃO DO PREÇO DE FECHAMENTO DE CRIPTOMOEDAS

Renan de Oliveira Ferretti (FT/UNICAMP), Prof. Dr. Guilherme Palermo Coelho(FT/UNICAMP), Prof. Dr. Arthur Emanuel de Oliveira Carosia (IFSP - campus São João da Boa Vista)

Financiamento: PIBIC/CNPq

Palavras-Chave: Criptomoedas, Redes Neurais Artificiais, Aprendizado de Máquina, Séries Temporais

INTRODUÇÃO

O termo criptomoeda se refere a uma moeda virtual que utiliza criptografia na realização de suas transações. Elas vêm sendo amplamente reconhecidas como um novo método alternativo de troca de capital, o que tem implicações consideráveis para a economia global [1]. Atualmente, pesquisadores se dedicam a analisar a eficiência do mercado e a volatilidade dos preços de criptomoedas [2]. O aprendizado de máquina é uma abordagem eficiente para desenvolver estratégias de compra e venda de criptomoedas [3], porque ele permite a inferência de relacionamentos de dados que muitas vezes não são diretamente observáveis por humanos. O presente trabalho de iniciação científica buscou realizar a predição da tendência de preço de criptomoedas no próximo dia a partir de dados históricos de suas cotações, i.e. dizer ao usuário se o valor irá subir ou descer no dia seguinte ao momento atual, o que caracteriza um problema de *classificação de dados*. Foram considerados preditores baseados em aprendizado de máquina e na estatística clássica para tal efeito.

METODOLOGIA

Para a realização das atividades foi utilizado o banco de dados público do *Yahoo Finance*, que contém dados diários de cotação das principais criptomoedas do mercado. A base de dados em questão possui dados do preço de abertura, preço de fechamento, maior preço alcançado no dia, menor preço alcançado no dia e volume de transações da criptomoeda no dia. No presente trabalho, foram selecionadas cinco criptomoedas para realizar os experimentos, sendo elas: Bitcoin (BTC), Ethereum (ETH), Tether (USDT), BNB e USD Coin (USDC). Após a obtenção da base de dados de cada criptomoeda considerada no projeto, foi necessário definir uma metodologia para os experimentos, conforme a Figura 1. No módulo “Algoritmo”, foram implementados o SVM, MLP, LSTM e ARIMA para realizar a predição.

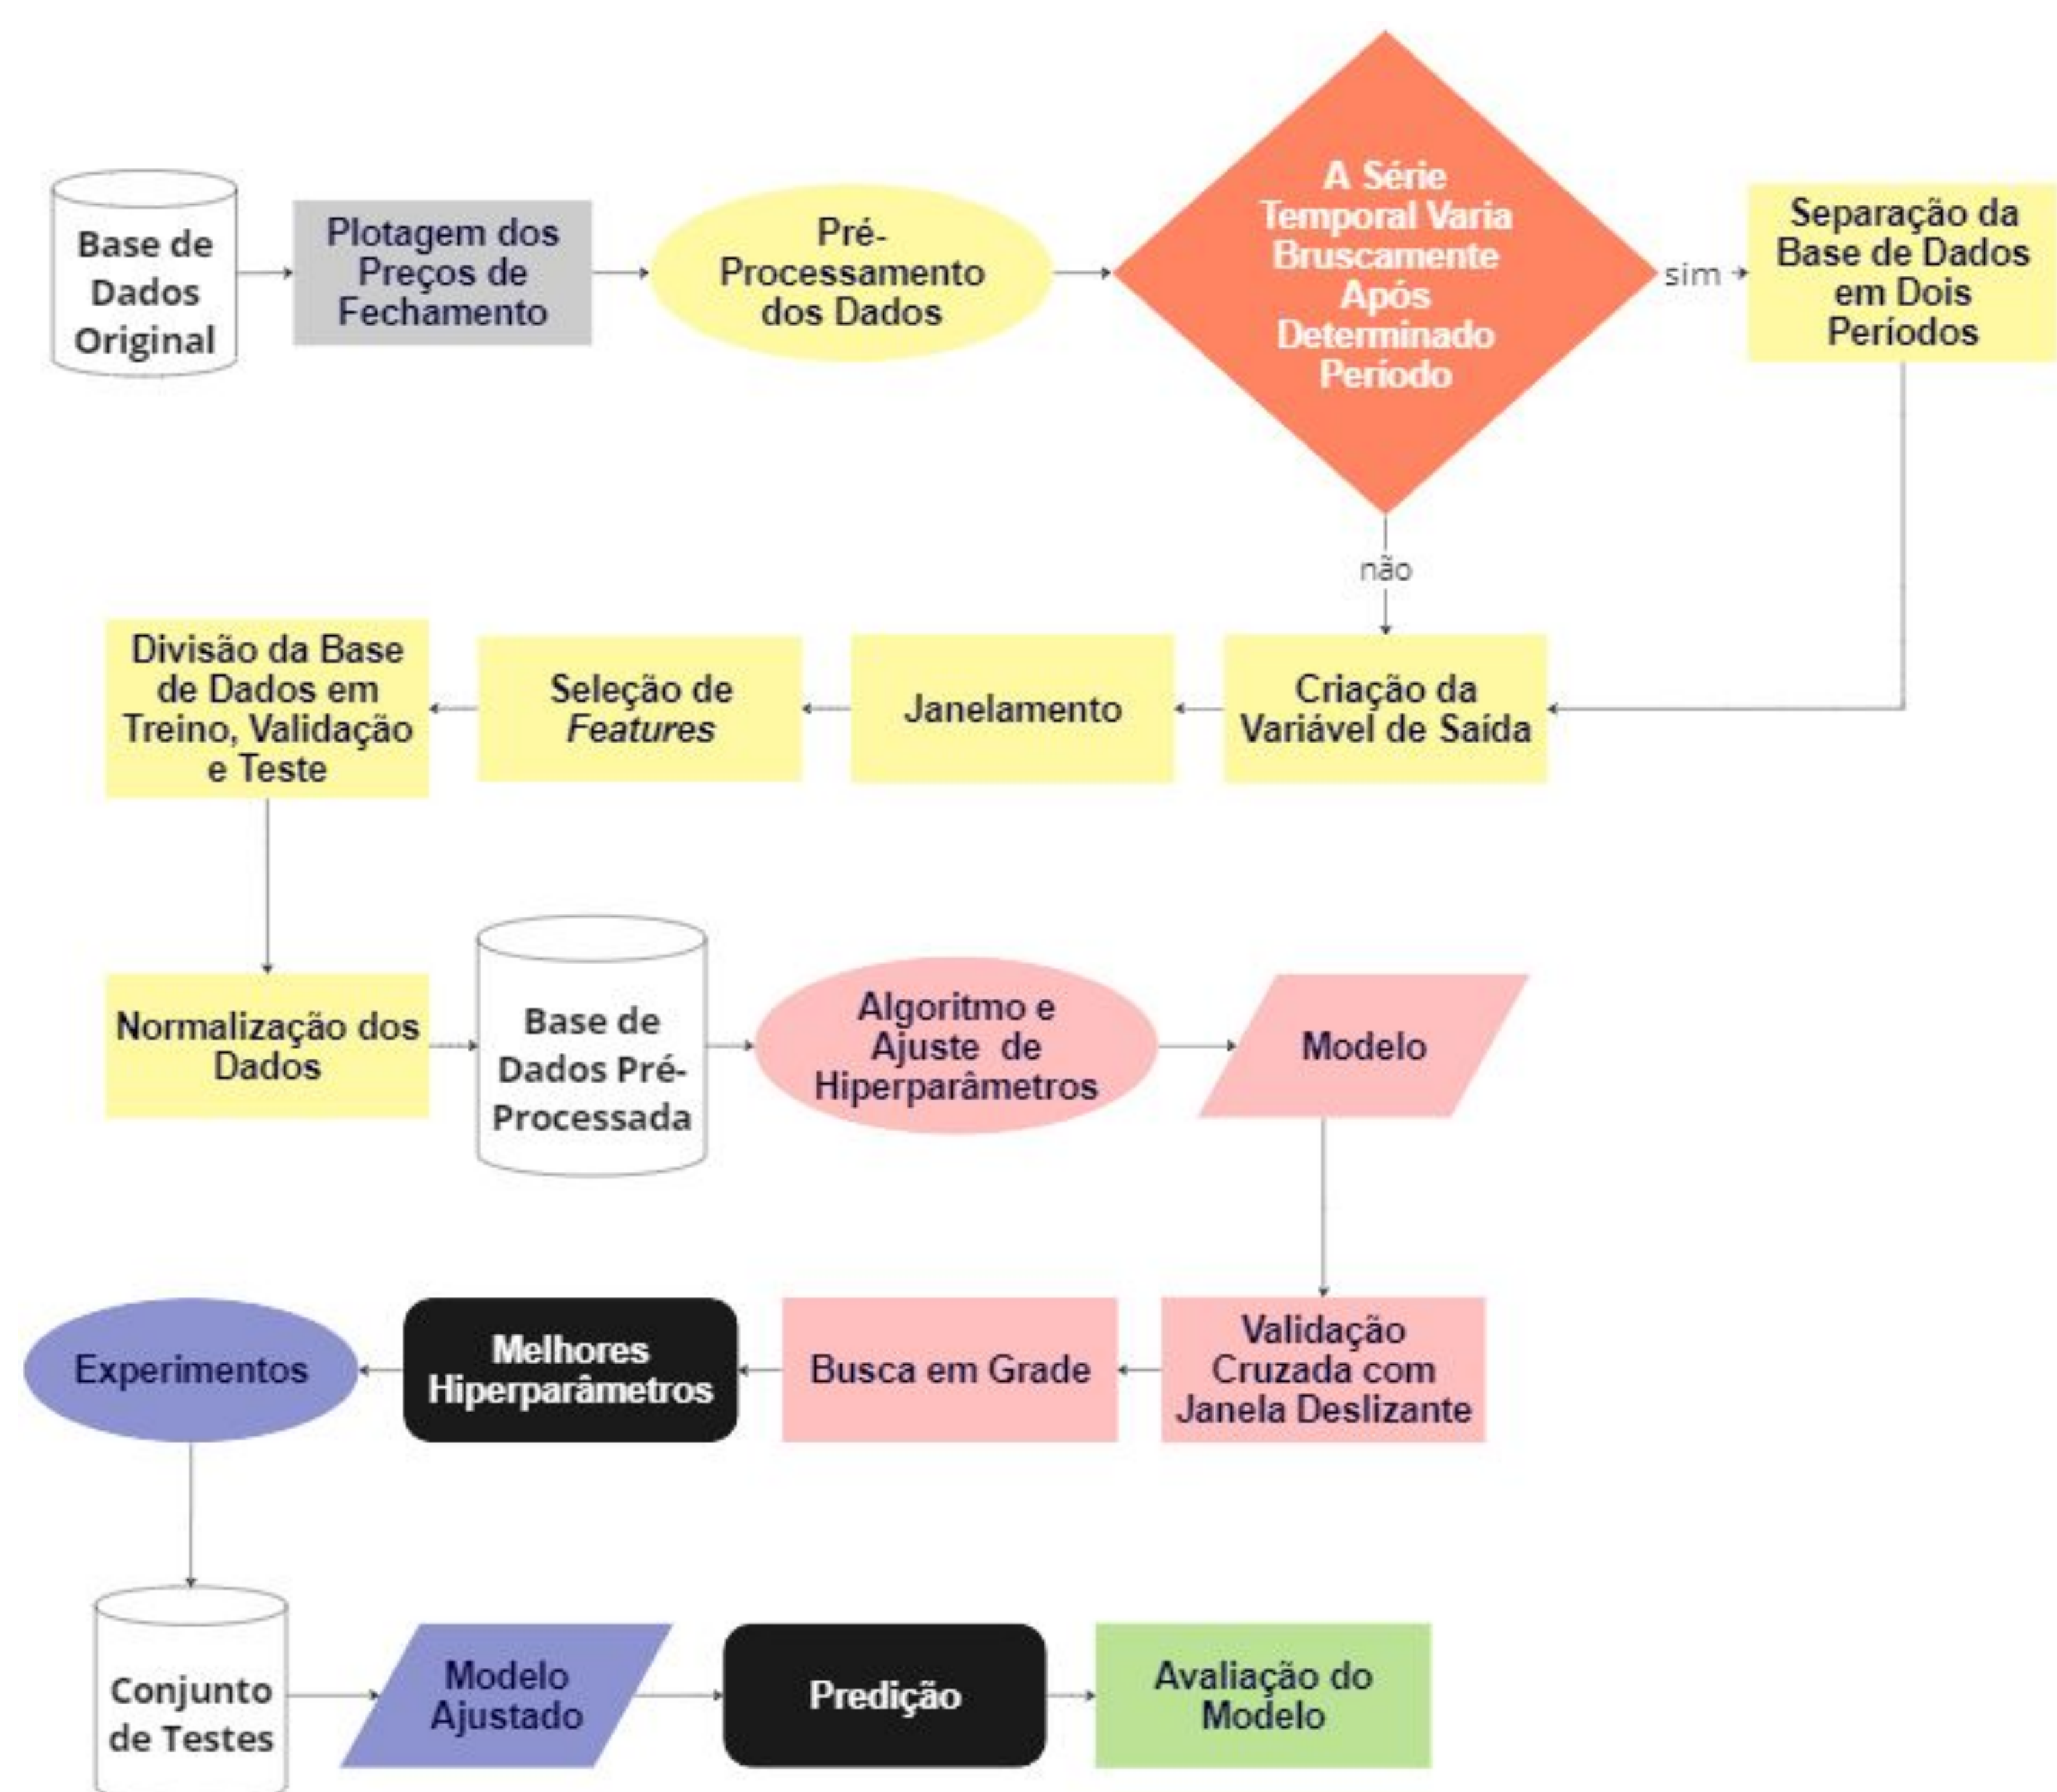


Figura 1: Diagrama da metodologia aplicada

RESULTADOS E DISCUSSÃO

Na Tabela 1 são apresentadas as melhores medidas obtidas para cada criptomoeda. De maneira geral, nos experimentos realizados tivemos comportamentos diferentes por parte de cada algoritmo. A SVM e a LSTM apresentaram resultados satisfatórios para todas as cinco criptomoedas, com destaque para a BNB, BTC e ETH. A melhor arquitetura usada pela SVM para essas três criptomoedas foi kernel linear, coeficiente do kernel automático e 0,2 de nu (BNB); kernel polinomial, coeficiente do kernel escalar e 0,2 de nu (BTC); e kernel linear, coeficiente do kernel automático e 0,2 de nu (ETH). Já a arquitetura empregada pela LSTM foi de 2 camadas ocultas, 30 neurônios por camada e 0,001 como taxa de aprendizado (BNB); 1 camada oculta, 50 neurônios por camada e 0,005 como taxa de aprendizado (BTC); e 3 camadas ocultas, 70 neurônios por camada e 0,001 como taxa de aprendizado (ETH). Em relação à rede neural do tipo MLP, ela teve um ótimo desempenho na predição do preço de fechamento da BNB e ETH, porém não conseguiu ter o mesmo rendimento para as demais criptomoedas. Já o ARIMA atingiu resultados inferiores aos modelos baseados em aprendizado de máquina para todas criptomoedas. A SVM obteve o melhor desempenho entre todas as predições ao realizar a previsão para a BNB, com F1-score de 98,94% e acurácia de 98,89%. Dessa forma, considerando a complexidade do modelo e seu desempenho, verificamos que os modelos mais simples são competitivos com opções inspiradas em redes neurais artificiais, podendo até superar determinadas abordagens.

Tabela 1: Resultados dos melhores modelos para cada criptomoeda

Criptomoeda	Melhor modelo	F1-Score	Acurácia
BNB	SVM	98,94%	98,89%
BTC	SVM	97,04%	97,16%
ETH	SVM	94,91%	95,02%
USDC	LSTM	84,96%	83,48%
USDT	LSTM	87,50%	85,89%

CONCLUSÕES

O projeto mostrou, através de diferentes modelos de predição, que o emprego de técnicas tradicionais de aprendizado de máquina podem ser capazes de superar modelos baseados em RNAs. Dentre as opções testadas, a SVM foi a que atingiu o melhor desempenho médio entre as cinco criptomoedas utilizadas; a LSTM também alcançou resultados bastante satisfatórios, mas um pouco inferiores aos da SVM. Em relação às criptomoedas, a BNB foi a qual os classificadores obtiveram os melhores resultados no conjunto de testes.

BIBLIOGRAFIA

- [1] NASIR, M.A.; HUYNH, T.L.D.; NGUYEN, S.P.; DUONG, D. Forecasting cryptocurrency returns and volume using search engines. **Financ. Innov.** 2019, 5, 2.
- [2] BALCILAR, Mehmet; BOURI, Elie; GUPTA, Rangan; ROUBAUD, David. Can volume predict Bitcoin returns and volatility? A quantiles-based approach. **Economic Modelling**, [S.L.], v. 64,, p. 74-81, ago. 2017.
- [3] MCNALLY, Sean; ROCHE, Jason; CATON, Simon. Predicting the Price of Bitcoin Using Machine Learning. **2018 26Th Euromicro International Conference On Parallel, Distributed And Network-Based Processing (Pdp)**, mar. 2018.